

YADLRetina

Yet Another Deep Learning Retina

Rubén Crespo Cano

<https://about.me/rubencrespocano>

HackLab Almería - 8 de noviembre de 2018

About me

Estudios

Ingeniería en Informática (2006-2012)

Máster en Ingeniería de Telecomunicación (2012-2015)

Doctorado en Informática (2015-Presente)

Experiencia profesional

EverSaaS - Ingeniero de Software (2012-Presente)

Universidad de Oldemburgo - Visiting PhD Student (2017)

Autores

Universidad de Alicante

Rubén Crespo-Cano

Antonio Martínez-Álvarez

Sergio Cuenca-Asensi

Universidad Miguel Hernández

Eduardo Fernández

Carl von Ossietzky Universität Oldenburg

Martin Greschner

Índice

1. Introducción

1.1. Motivación

1.2. Retina

1.3. Neuroprótesis visuales

1.4. Objetivo

1.5. Enfoque

2. Materiales y Métodos

2.1. Registros electrofisiológicos

2.2. Deep learning

3. Resultados y Discusión

4. Conclusiones y Trabajo futuro

INTRODUCCIÓN

Motivación

Motivación

Más de 40 millones de personas en el mundo son ciegas.

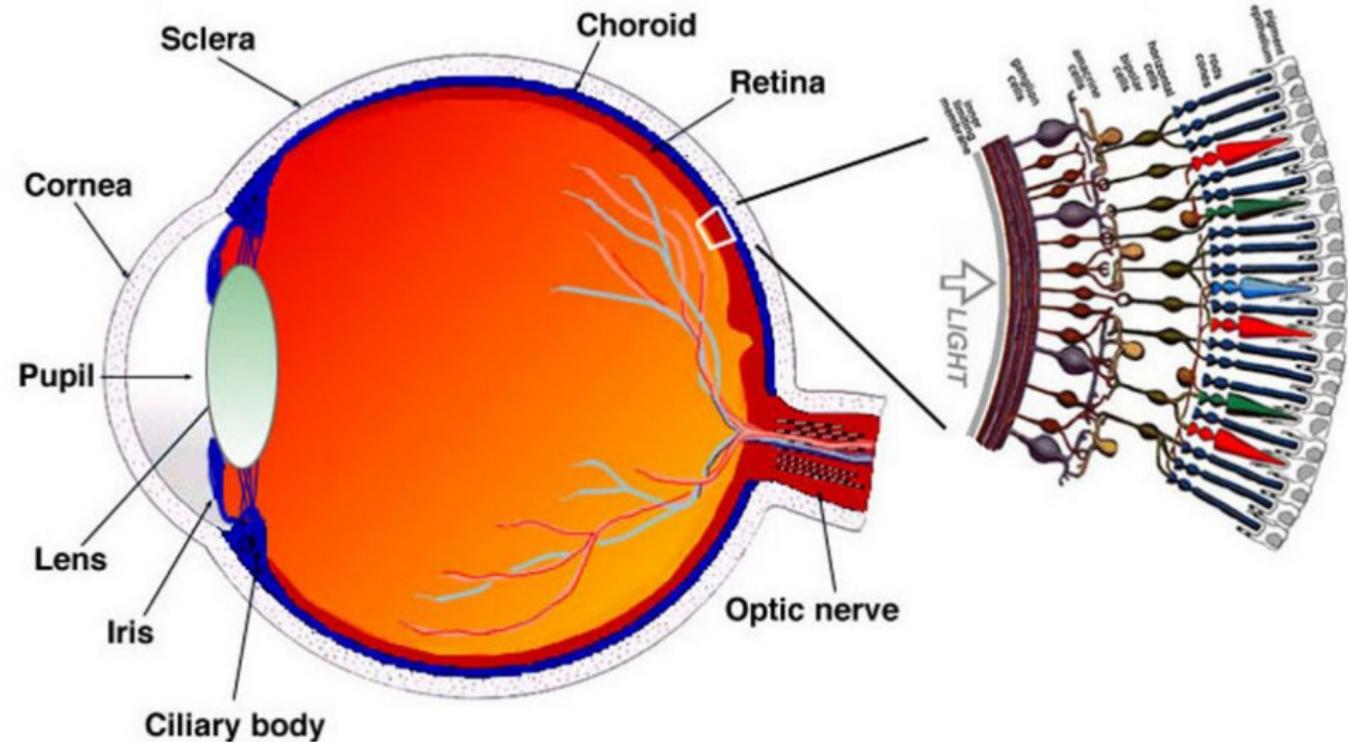
- Pérdida de independencia personal.
- Costes personales y sociales.

Existencia de tratamientos médicos, cirugía y terapias genéticas.

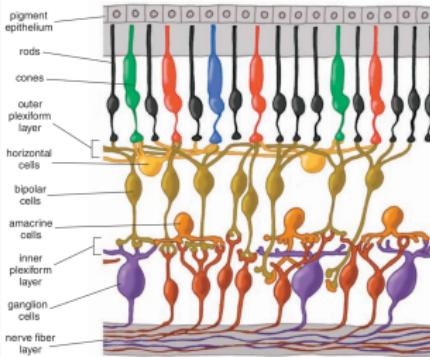
- No útil para AMD, RP, glaucoma, atrofia del nervio óptico, etc.

En tales casos, una *prótesis visual* puede ser la única opción.

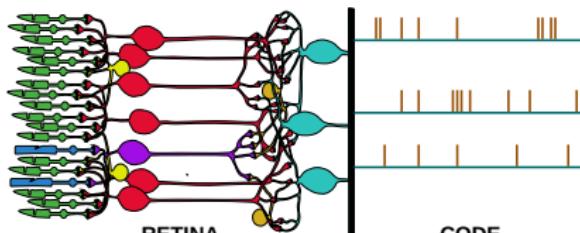
Retina



Retina



VISUAL INFORMATION



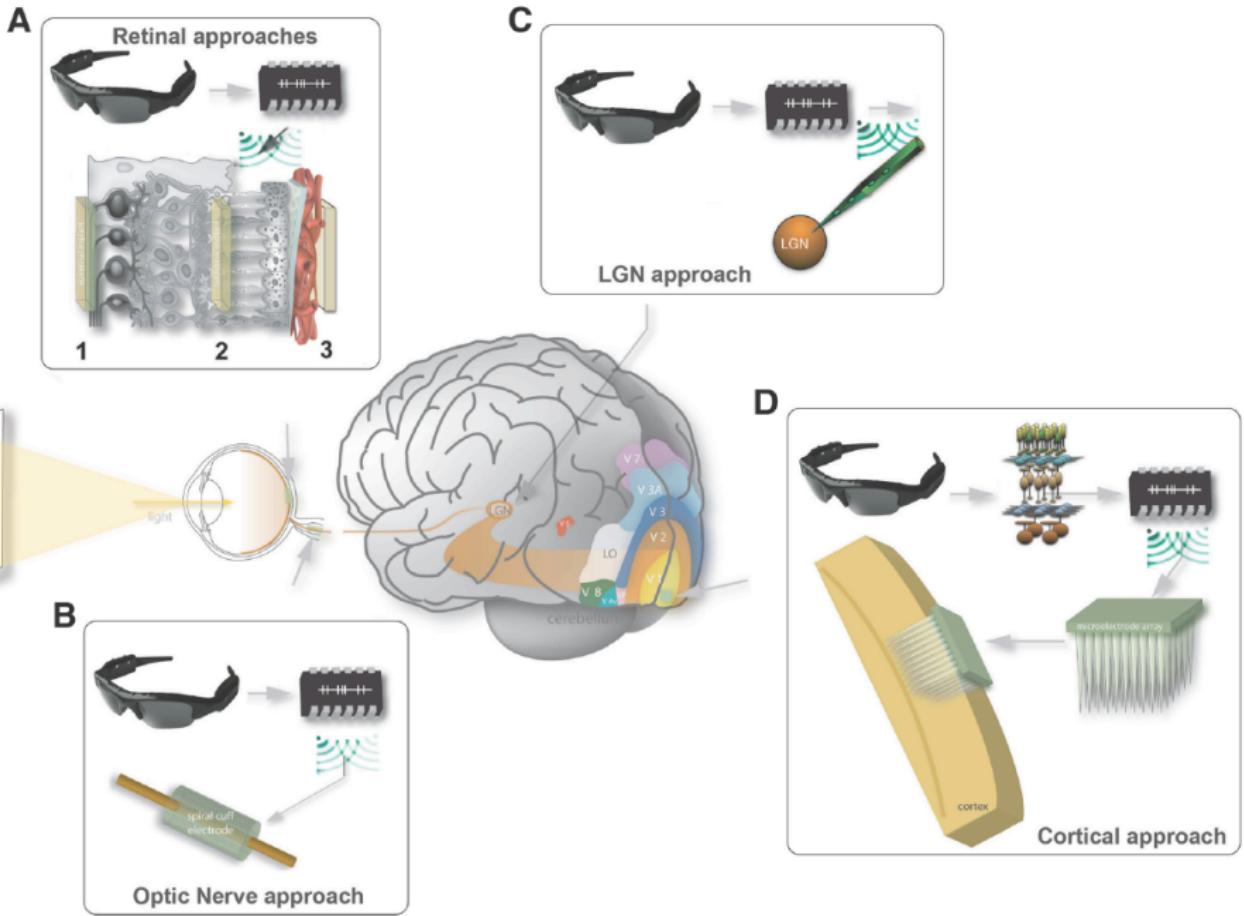
RETINA

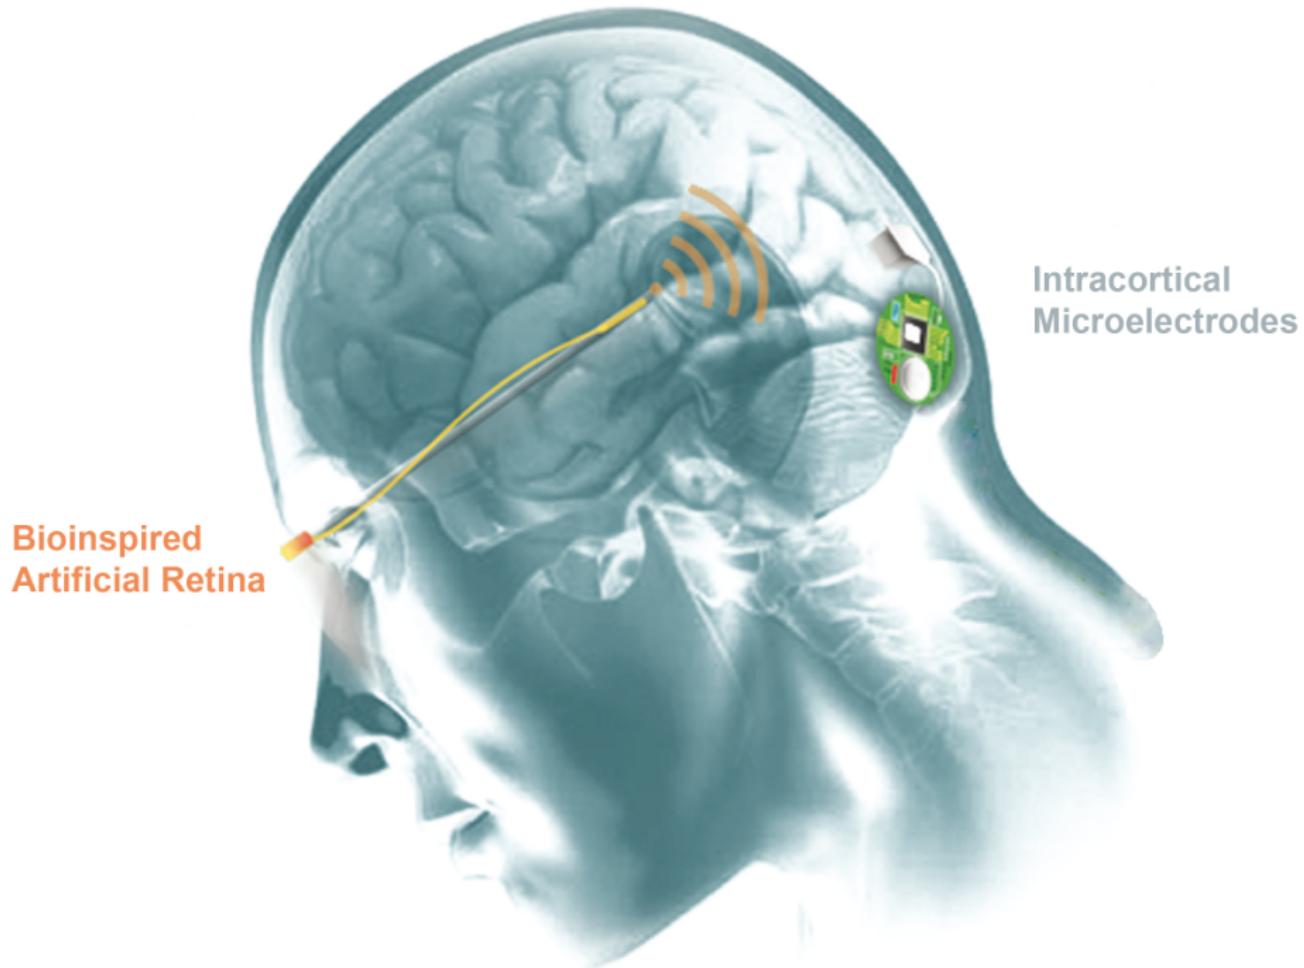
CODE

BRAIN

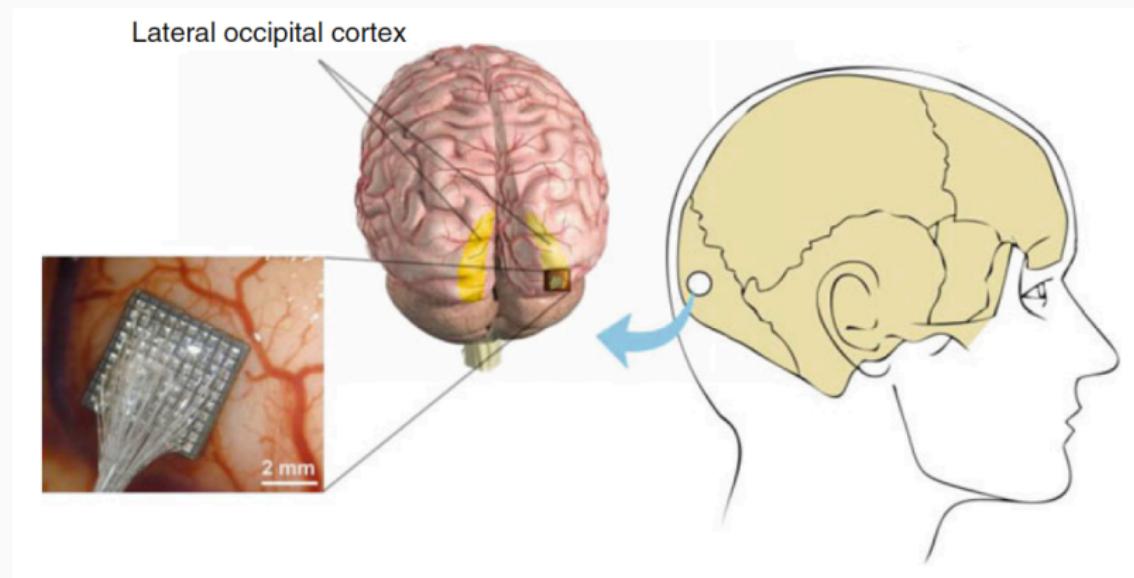


Neuroprótesis visuales

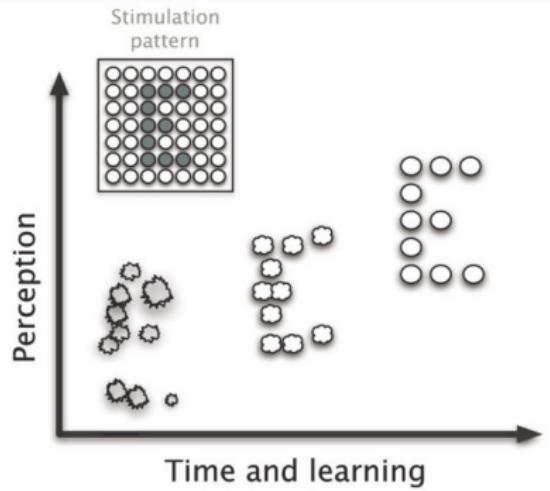




Procedimiento de implantación



■ Neuroprótesis cortical



Objetivo

Comprender las respuestas sensoriales a los estímulos de ruido natural.

Modelo de retina

- ¿Predicción de respuestas neuronales?
- ¿Correspondencia entre la estructura biológica y el modelo?

Enfoque

Entrenar redes de aprendizaje profundo para modelar las respuestas de la retina ante estímulos de ruido natural.

Comprobar si los modelos exhiben un comportamiento y una estructura acorde con la disposición de las capas neuronales de la retina.

MATERIALES Y MÉTODOS

Registros electrofisiológicos

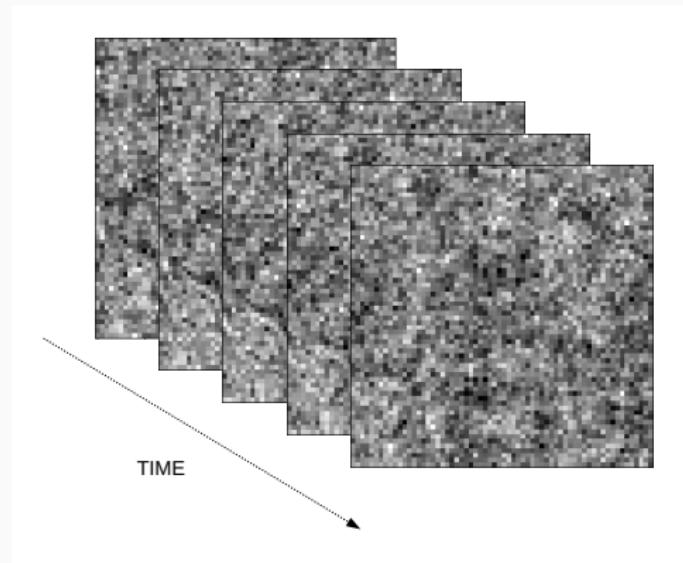


■ Estímulo visual

Estimulación de las retinas

Ruido natural ($1/f$) o ruido rosa.

Tasa de refresco de 120 Hz.



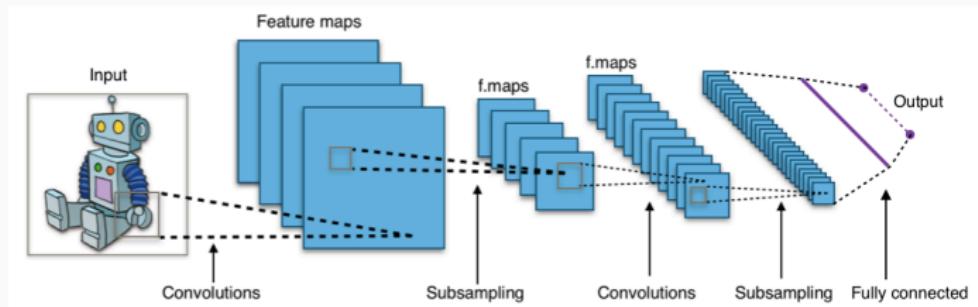
Demo time

Deep learning

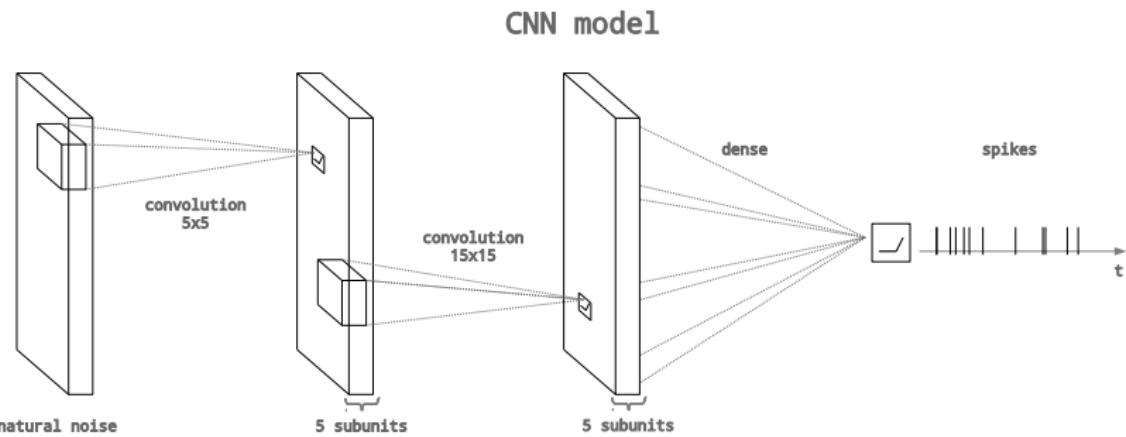
CNNs

Convolutional Neural Networks (CNNs).

- Variantes bioinspiradas de MLPs.
- Basadas en la estructura del cortex visual.
- Células sensibles a sub-regiones del campo visual.
- Filtros locales que cubren todo el campo visual.
- Explotar correlación local espacial de las imágenes.
- Entrenamiento: minimizar error entre predicciones y datos.



Modelo individual de células ganglionares.



Inicialización: Distribución normal de pesos aleatorios.

Loss function: Binary Crossentropy.

Optimización: ADAM.

Time window: 250 ms.

Filtros espacio-temporales: 5 y 5.

Kernels: 5px y 15px.

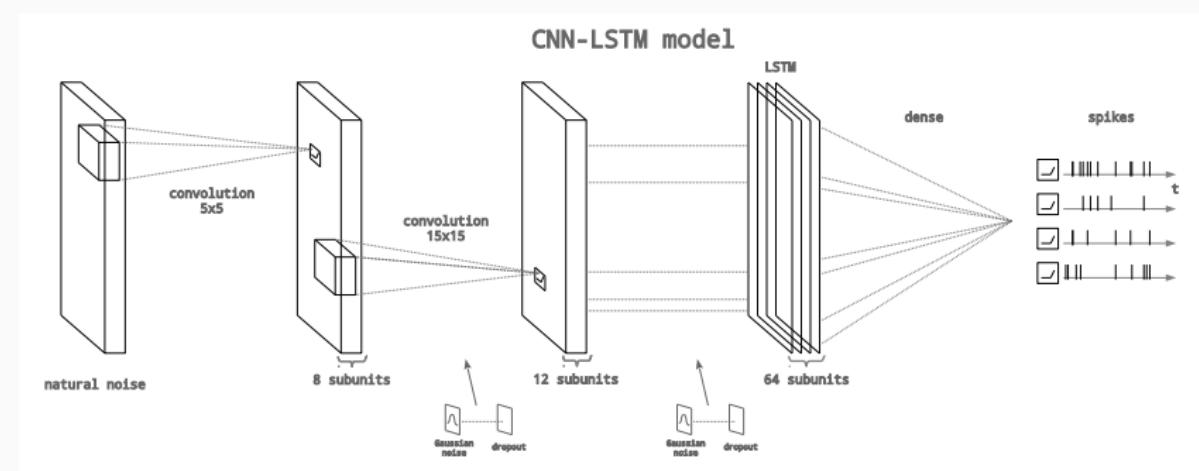
100 epochs.

Early-stopping method (conjunto de validación).

Parámetros: $\approx 150,000$.

CNN-LSTM

Modelo población de células ganglionares.



CNN-LSTM

Inicialización: Distribución normal de pesos aleatorios.

Loss function: Binary Crossentropy.

Optimización: ADAM.

Time window: 250 ms.

Filtros espacio-temporales: 8 y 12.

Kernels: 5px y 15px.

100 epochs.

Early-stopping method (conjunto de validación).

Dropout (overfitting).

Gaussian noise (variabilidad interna).

L2 activity regularizers.

RNN: Long Short-Term Memory (LSTM).

Parámetros: $\approx 1,500,000$.



HW y SW



HW y SW

Tecnologías

Python (3.6).

TensorFlow (1.8.0 -> 1.10.1).

Keras (2.1.6 -> 2.2.2).

Infraestructura

HPC cluster (2x Intel XEON 48 GB RAM).

No GPU.

Código fuente

<https://github.com/rcrespocano/yadlretina>*

RESULTADOS Y DISCUSIÓN

Resultados

Experimentos:

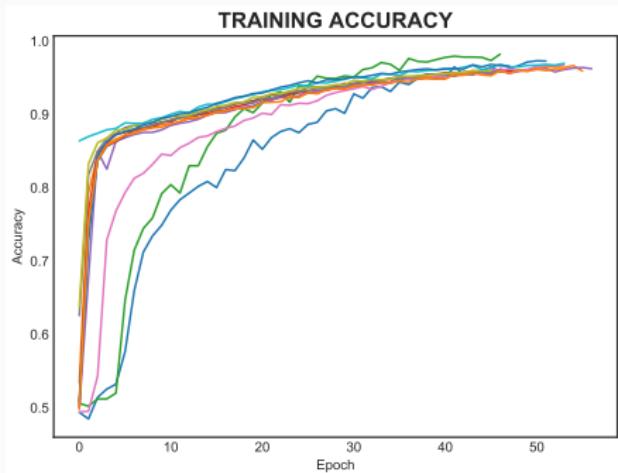
1. Estudio células individuales.
2. Población de células distintas.

Data set:

Traning, validation and test sets
50 min., 7 min. y 7 min.

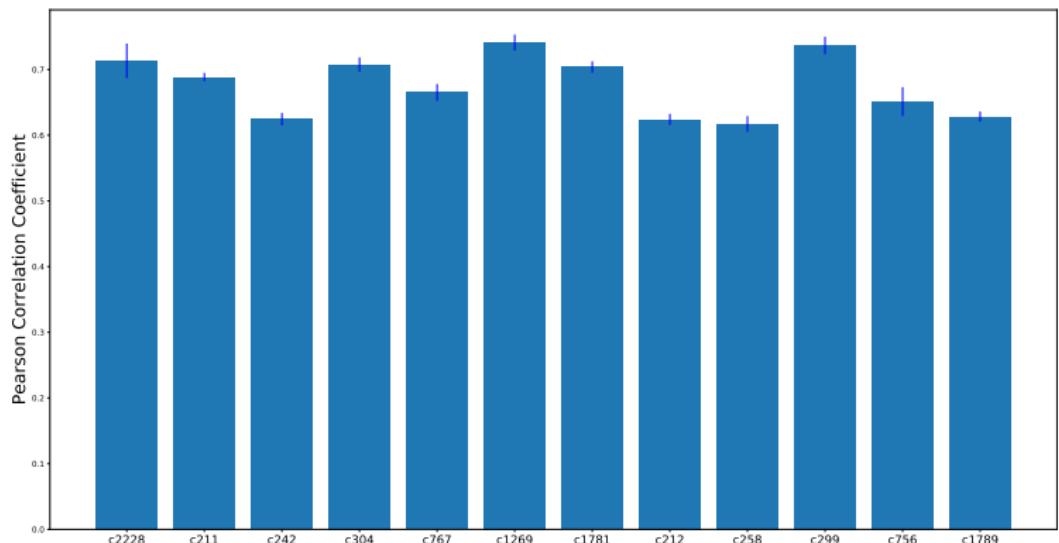
Resultados

Distribución de la media de la precisión para los conjuntos de entrenamiento y test.



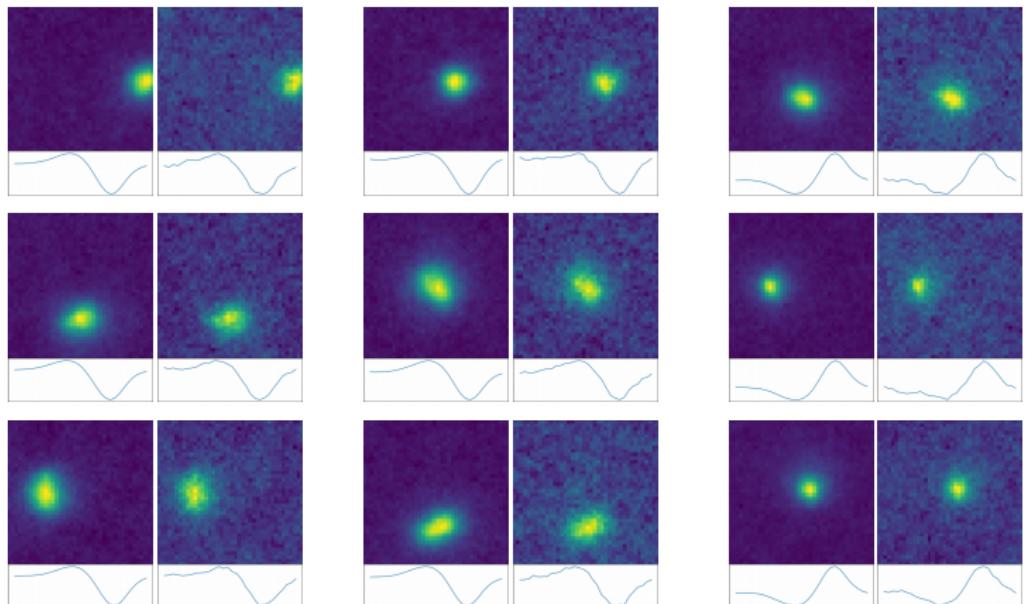
Resultados

Distribución del coeficiente de correlación de Pearson.



Resultados

Comparación de los campos receptivos (STA).

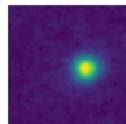


Resultados

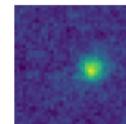
Filtros convolucionales: subunidades localizadas.

Transient OFF

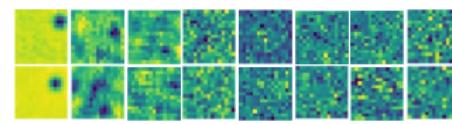
BIO RF



MODEL RF

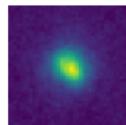


CONV FILTERS

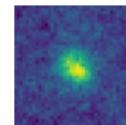


OFF large fast

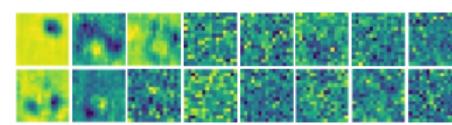
BIO RF



MODEL RF

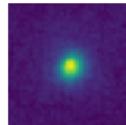


CONV FILTERS

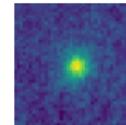


Transient ON

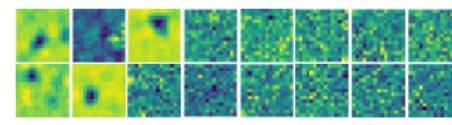
BIO RF



MODEL RF

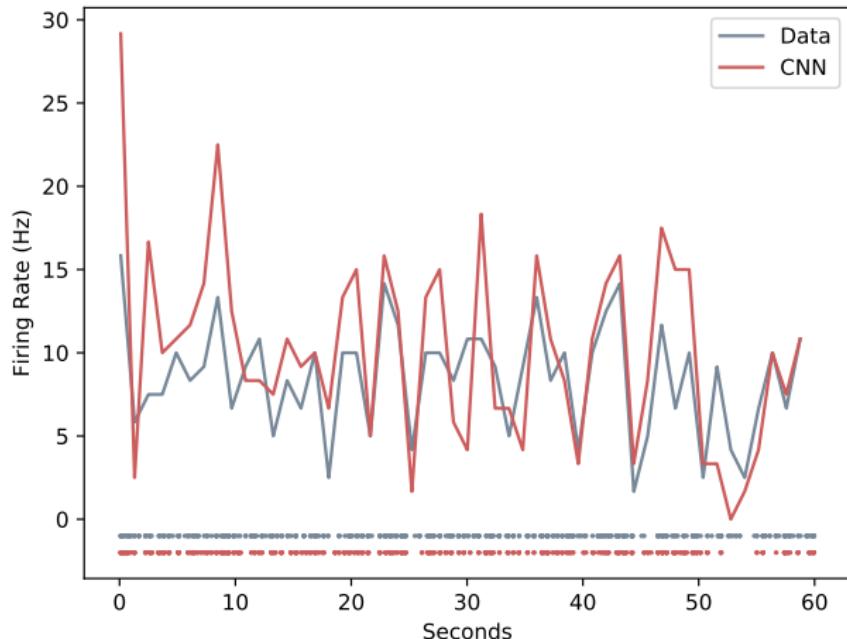


CONV FILTERS



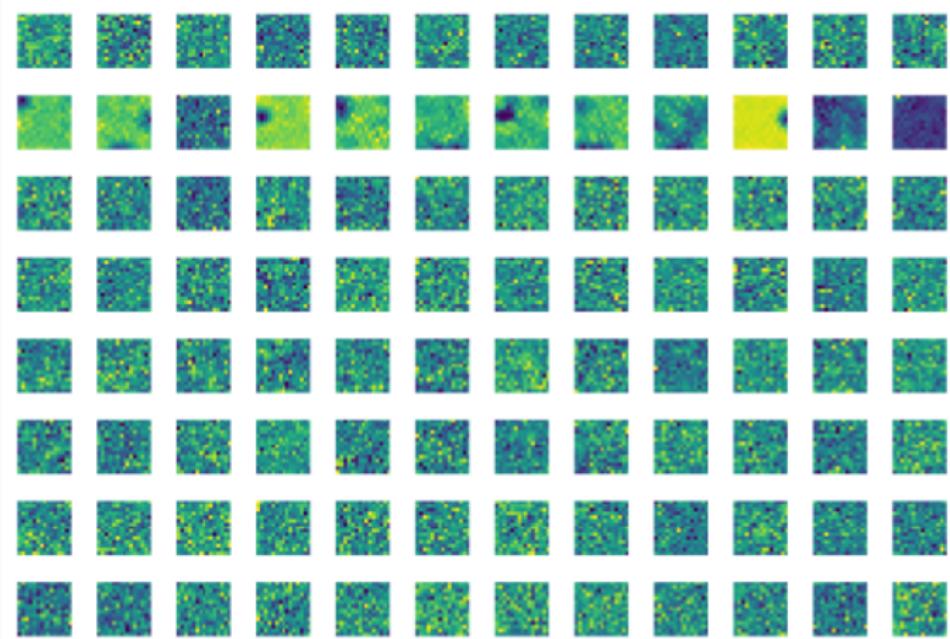
Resultados

Predicción precisa de respuestas sensoriales ($PCC \approx 0.70$).



Resultados

Transient OFF, large fast OFF y transient ON.



CONCLUSIONES Y TRABAJO FUTURO

CONCLUSIONES

Introducción de dos arquitecturas para codificar neuronas de la retina.

RGCs individuales y población de RGCs.

Reproducción de campos receptivos neuronales.

Predicción de respuestas neuronales ante ruido natural con un coeficiente de correlación de Pearson de hasta 0.70.

Las capas internas de los modelos CNNs son capaces de aprender y revelar componentes subyacentes de la retina.

Este conocimiento puede ser muy útil para abordar el reto del diseño de una neuroprótesis visual.

■ TRABAJO FUTURO

1. Escenas naturales.
2. GPU: GeForce GTX 1080 Ti.

A 3D reconstruction of a brain circuit, likely a fly brain, showing a dense network of neurons. The neurons are represented by colored, bulbous structures connected by thin, branching lines. The colors include various shades of red, green, blue, yellow, purple, and orange. The background is a grayscale representation of the brain's architecture.

iGracias!

@rcrespocano

YADLRetina

Yet Another Deep Learning Retina

Rubén Crespo Cano

<https://about.me/rubencrespocano>

HackLab Almería - 8 de noviembre de 2018